華中科技大學

2023

计算机视觉实验报告

上机实验二: 基于卷积神经网络的 CIFAR-10 数据集分类

专业:计算机科学与技术班级:计科 2008 班学号:U202015550姓名:刘方兴完成日期:2023 年 4 月 3 日



目 录

	1. 深度学习框架	1
	1.1 编程环境	1
	1.2 框架选择	1
	1.3 代码结构设计	1
2	实验过程设计	6
	2.1 基本实验模型	6
	2.2 数据增强及正则化参数添加	9
	2.3 增加网络深度及正则化参数大小	.11
	2.4 基于实验经验构建的最终网络模型(网络模型优化+学习率动	协态
	调整)	.15
3	实验分析	18
	3.1 实验结果分析	.18
	3.2 不同网络结构对比(含激活函数对比)	.19
4	总结	21
	4.1 实验总结	.21
	4.2 提交文件	.21

1. 深度学习框架

1.1 编程环境

开发环境:

jupyter notebook (本地版)

https://featurize.cn/ (云 GPU)

辅助工具:wandb—对实验过程进行实时监控、实现数据可视化

1.2 框架选择

基本框架: tensorflow

1.3 代码结构设计

1) 工具包导入及 GPU 环境设置部分

```
import tensorflow as tf
from tensorflow.keras import regularizers
from tensorflow.keras.callbacks import ModelCheckpoint
import matplotlib.pyplot as plt
from tensorflow.keras.models import load_model
import numpy as np
import matplotlib.pyplot as plt
from sklearn.metrics import confusion_matrix
import itertools
## 获取可用的 GPU 设备列表
# gpus = tf.config.experimental.list_physical_devices('GPU')
##如果没有可用的 GPU 设备,则输出错误信息
# if not gpus:
     print("No available GPU devices!")
"
# else:
# # 輸出可用的 GPU 设备信息
         print(gpu)
# # 指定使用的 GPU
# gpus = tf.config.experimental.list_physical_devices('GPU')
# tf.config.experimental.set_visible_devices(gpus[0], 'GPU')
```

2) 实验数据准备部分

<1>数据增强

```
# 定义训练集和测试集的数据增强
train_transform = tf.keras.Sequential([
    tf.keras.layers.experimental.preprocessing.RandomFlip('horizontal'),
    tf.keras.layers.experimental.preprocessing.RandomRotation(0.1),
    tf.keras.layers.experimental.preprocessing.RandomTranslation(0.1, 0.1),
    tf.keras.layers.experimental.preprocessing.RandomZoom(0.1),
    tf.keras.layers.experimental.preprocessing.Rescaling(1./255)
])
test_transform = tf.keras.Sequential([
    tf.keras.layers.experimental.preprocessing.Rescaling(1./255)
])
```

<2>超参数定义

```
# 定义超参数
lr = 0.001
batch_size = 256
num_epochs = 100
```

<3>学习率动态调整

```
def lr_schedule(epoch, lr):
    if epoch % 20 == 0 and epoch > 0:
        lr = lr / 2
    return lr
#定义动态学习率调整机制
lr_scheduler = tf.keras.callbacks.LearningRateScheduler(lr_schedule)
```

<4>实验数据导入及预处理

```
# 加载 CIFAR-10 数据集
(x_train, y_train), (x_test, y_test) = tf.keras.datasets.cifar10.load_data()
# 持标签转换为 one-hot 编码
y_train = tf.keras.utils.to_categorical(y_train, num_classes=10)
y_test = tf.keras.utils.to_categorical(y_test, num_classes=10)
# 对训练兼和副冰集动音位进行数据增强和格准处理
train_dataset = tf.data.Dataset.from_tensor_slices((x_train, y_train))
train_dataset = train_dataset.shuffle(buffer_size=10000)
train_dataset = train_dataset.shuffle(buffer_size=10000)
train_dataset = train_dataset.shuffle(buffer_size=10000)
train_dataset = train_dataset.shuffle(buffer_size=10000)
train_dataset = train_dataset.shufch(batch_size=batch_size)
train_dataset = train_dataset.prefetch(tf.data.experimental.AUTOTUNE)

test_dataset = test_dataset.map(lambda x, y: (test, y_test))
test_dataset = test_dataset.map(lambda x, y: (test, y_test))
test_dataset = test_dataset.batch(batch_size=batch_size)
test_dataset = test_dataset.prefetch(tf.data.experimental.AUTOTUNE)

# 定义优化器和损失函数
optimizer = tf.keras.optimizers.Adam(learning_rate=0.001)
loss_fn = tf.keras.losses.CategoricalCrossentropy()

# 定义回调函数,保存最佳模型
checkpoint_path = 'my_model_final_best.h5'
checkpoint_path = 'my_model_final_best.h5'
checkpoint = ModelCheckpoint(checkpoint_path, monitor='val_accuracy', save_best_only=True,_mode='max'._verbose=1)

# 網译模型
model.compile(optimizer=optimizer, loss=loss_fn, metrics=['accuracy'])

# 训练模型
history = model.fit(train_dataset, epochs=num_epochs, validation_data=test_dataset_callbacks=[checkpoint_ir_scheduler])
```

3) 实验模型设计部分

4)输出结果可视化部分

<1>可视化显示训练集和测试集的 loss、accuracy

```
# 可認化显示训练集和测试集的loss
plt.plot(history.history['loss'])
plt.plot(history.history['val_loss'])
plt.title('Model loss')
plt.ylabel('Loss')
plt.xlabel('Epoch')
plt.legend(['Train', 'Validation'], loc='upper right')
plt.show()

# 可認化显示训练集和测试集份accuracy
plt.plot(history.history['accuracy'])
plt.plot(history.history['val_accuracy'])
plt.title('Model accuracy')
plt.ylabel('Accuracy')
plt.xlabel('Epoch')
plt.legend(['Train', 'Validation'], loc='lower right')
plt.show()
```

<2> 可视化每个类别的准确率

```
# 预测测试集的标签
y_pred = model.predict(test_dataset)
# 计算每个类别的准确率
correct_counts = [0] * 10
total_counts = [0] * 10
for i in range(len(y_pred)):
   pred_label = tf.argmax(y_pred[i]).numpy()
    true_label = tf.argmax(y_test[i]).numpy()
    total_counts[true_label] += 1
    if pred_label = true_label:
        correct_counts[true_label] += 1
# 打印每个类别的准确率
for i in range (10):
    acc = correct_counts[i] / total_counts[i]
    print('Class {}: {} accuracy: {:.2%}'.format(i, class_names[i] ,acc))
# 可视化每个类别的准确率
class_names = ['airplane', 'automobile', 'bird', 'cat', 'deer', 'dog', 'frog', 'horse', 'ship', 'truck']
accuracies = [correct_counts[i] / total_counts[i] for i in range(10)]
x_pos = np. arange(len(class_names))
plt.bar(x_pos, accuracies)
plt.xticks(x_pos, class_names, rotation='vertical')
plt.ylabel('Accuracy')
plt.title('Accuracy by Class')
plt.show()
```

<3> 绘制预测结果混淆矩阵

```
# 预测测试集的结果
y_pred_classes = np.argmax(y_pred, axis=1)
y_true = np.argmax(y_test, axis=1)
confusion_mtx = confusion_matrix(y_true, y_pred_classes)
def plot_confusion_matrix(cm, classes, normalize=False, cmap=plt.cm.Blues):
   if normalize:
       cm = cm.astype('float') / cm.sum(axis=1)[:, np.newaxis]
       print("Normalized confusion matrix")
       print('Confusion matrix, without normalization')
   print(cm)
   plt.imshow(cm, interpolation='nearest', cmap=cmap)
   plt.title('Confusion matrix')
   plt.colorbar()
    tick_marks = np.arange(len(classes))
   plt.xticks(tick_marks, classes, rotation=45)
   plt.yticks(tick_marks, classes)
   fmt = '.2f' if normalize else 'd'
   thresh = cm.max() / 2.
   for i, j in itertools.product(range(cm.shape[0]), range(cm.shape[1])):
       plt.text(j, i, format(cm[i, j], fmt),
                horizontalalignment="center"
                color="white" if cm[i, j] > thresh else "black")
   plt.tight_layout()
   plt.ylabel('True label')
   plt.xlabel('Predicted label')
plot_confusion_matrix(confusion_mtx, class_names)
```

5) 模型保存部分

```
# 定义回调函数,保存最佳模型
checkpoint_path = 'my_model_final_best.h5'
checkpoint = ModelCheckpoint(checkpoint_path, monitor='val_accuracy', save_best_only=True, _mode='max', _verbose=1)
```

```
model.save('my_model_final.h5')_#_保存为.h5格式

# 读取模型
model = load_model('my_model_final_best.h5')

# 进行测试
test_loss, test_acc = model.evaluate(test_dataset)
print('Test accuracy:', test_acc)
```

2. 实验过程设计

2.1 基本实验模型

```
# 定义卷积神经网络模型
model = tf.keras.Sequential([
    tf.keras.layers.Conv2D(64, 3, padding='same', activation='relu', input_shape=(32, 32, 3)), # 输入通道数为3. 输出通道数为64. 卷积核大小
    tf.keras.layers.Conv2D(64, 3, padding='same', activation='relu'), # 輸入通道数为64. 输出通道数为64. 卷积核大小
    tf.keras.layers.MaxPooling2D(2, 2), # 最大池化层, 大小为2x2. 步幅为2
    tf.keras.layers.Conv2D(128, 3, padding='same', activation='relu'),
    tf.keras.layers.Conv2D(128, 3, padding='same', activation='relu'),
    tf.keras.layers.MaxPooling2D(2, 2),
    tf.keras.layers.MaxPooling2D(2, 2),
    tf.keras.layers.Conv2D(256, 3, padding='same', activation='relu'),
    tf.keras.layers.MaxPooling2D(2, 2),
    tf.keras.layers.MaxPooling2D(2, 2),
    tf.keras.layers.Flatten(), # 将张量展开为一维张量
    tf.keras.layers.Flatten(), # 将张量展开为一维张量
    tf.keras.layers.Dense(1024, activation='relu'),
    tf.keras.layers.Dense(512, activation='relu'),
    tf.keras.layers.Dense(10, activation='relu'),
    tf.keras.layers.Dense(10, activation='relu'),
    tf.keras.layers.Dense(10, activation='relu'),
    tf.keras.layers.Dense(10, activation='relu'),
    tf.keras.layers.Dense(10, activation='softmax') # 輸出层、輸入維度为512, 輸出維度为10
```

基于 tf. keras. Sequential 搭建一个最基本的卷积神经网络模型,模型结构如下 (示意图使用 tf. keras. utils. plot model 打印):

ayer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 32, 32, 64)	1792
conv2d_1 (Conv2D)	(None, 32, 32, 64)	36928
max_pooling2d (MaxPooling2D)	(None, 16, 16, 64)	0
conv2d_2 (Conv2D)	(None, 16, 16, 128)	73856
conv2d_3 (Conv2D)	(None, 16, 16, 128)	147584
max_pooling2d_1 (MaxPooling 2D)	(None, 8, 8, 128)	0
conv2d_4 (Conv2D)	(None, 8, 8, 256)	295168
conv2d_5 (Conv2D)	(None, 8, 8, 256)	590080
max_pooling2d_2 (MaxPooling 2D)	(None, 4, 4, 256)	0
flatten (Flatten)	(None, 4096)	0
dense (Dense)	(None, 1024)	4195328
dense_1 (Dense)	(None, 512)	524800
dense_2 (Dense)	(None, 10)	5130

图 2.1 基本模型结构

科 技 大 课程设 计 报告





图 2.2 基本模型示意图

实验测试结果






图 2.3 基本模型实验结果图

在运行 20 个 epoch 后,可以看到模型在训练集上的准确率达到了 0.8713,但自从第 10 个 epoch 开始,模型在测试集上的准确率并没有明显的提升,始终保持在 0.76 左右。

这反映出两个问题:

第一: 模型的整体识别效果并不是很好, 准确率还不够高。

第二:模型仅仅在训练集上表现好,这说明模型存在过拟合的现象。

2.2 数据增强及正则化参数添加

1.在保持网络架构基本不变的前提下,增加数据增强部分:

```
# 定义训练集和测试集的数据增强
train_transform = tf. keras. Sequential([
    tf. keras. layers. experimental. preprocessing. RandomFlip('horizontal'),
    tf. keras. layers. experimental. preprocessing. RandomRotation(0.1),
    tf. keras. layers. experimental. preprocessing. RandomZoom(0.1),
    tf. keras. layers. experimental. preprocessing. Rescaling(1./255)
])


test_transform = tf. keras. Sequential([
    tf. keras. layers. experimental. preprocessing. Rescaling(1./255)
])
```


2.在保持网络架构基本不变的前提下,增加 dropout 和 L2 正则化系数:

实验结果:

20个 epoch:

```
Epoch 28/40
98/98 [===
Epoch 29/40
                                       =] - 194s 2s/step - loss: 0.6265 - accuracy: 0.8244 - val_loss: 0.8977 - val_accuracy: 0.7655
98/98 [=
                                     ==] - 197s 2s/step - loss: 0.6099 - accuracy: 0.8305 - val_loss: 0.8259 - val_accuracy: 0.7772
Epoch 30/40
                                      = - 191s 2s/step - loss: 0.6041 - accuracy: 0.8319 - val loss: 0.8036 - val accuracy: 0.7809
98/98 [=
Epoch 31/40
98/98 [===
                                       =] - 193s 2s/step - loss: 0.5930 - accuracy: 0.8363 - val_loss: 0.8630 - val_accuracy: 0.7763
Epoch 32/40
98/98 [=
                                     ==] - 193s 2s/step - loss: 0.5800 - accuracy: 0.8400 - val_loss: 0.8376 - val_accuracy: 0.7798
Epoch 33/40
                                    ==] - 196s 2s/step - loss: 0.5751 - accuracy: 0.8442 - val_loss: 0.8143 - val_accuracy: 0.7841
98/98 [=
Epoch 34/40
98/98 [===
                                      =] - 174s 2s/step - loss: 0.5505 - accuracy: 0.8521 - val_loss: 0.8399 - val_accuracy: 0.7819
Epoch 35/40
98/98 [===
Epoch 36/40
                                       =] - 164s 2s/step - loss: 0.5478 - accuracy: 0.8534 - val_loss: 0.8088 - val_accuracy: 0.7924
98/98 [===
Epoch 37/40
                                     ==] - 163s 2s/step - loss: 0.5364 - accuracy: 0.8567 - val_loss: 0.8361 - val_accuracy: 0.7892
98/98 [=
                                     — ] - 167s 2s/step - loss: 0.5327 - accuracy: 0.8600 - val loss: 0.8532 - val accuracy: 0.7905
Epoch 38/40
98/98 [===
                                      =] - 169s 2s/step - loss: 0.5286 - accuracy: 0.8612 - val_loss: 0.8749 - val_accuracy: 0.7770
Epoch 39/40
98/98 [===
                                       =] - 172s 2s/step - loss: 0.5079 - accuracy: 0.8685 - val_loss: 0.8904 - val_accuracy: 0.7783
Epoch 40/40
98/98 [=
                                    ===] - 175s 2s/step - loss: 0.4878 - accuracy: 0.8759 - val_loss: 0.8299 - val_accuracy: 0.7927
```





在运行 40 个 epoch 后,模型基本收敛,最终测试集上的 accuracy 接近 0.87,训练集上的 accuracy 接近 0.8

从防止过拟合的方面看: dropout 和 L2 正则化系数的添加一定程度上减少了模型的过拟合程度,增加了模型的泛化能力。但测试集上的 accuracy 与训练集上的 accuracy 还是存在不小的差距。

从模型预测准确率上来看:数据增强并没有在防止过拟合的基础上为模型的预测准确率带来非常大的提升。

综上,我考虑从模型本身入手,在尝试增加神经网络的深度的同时也将模型的正则 化参数调的大一些。

2.3 增加网络深度及正则化参数大小


构建新的卷积神经网络结构:


	Layer (type)	Output Shape	Param #	batch_normalization_1 (Batc (None, 16, 16, 128) 5. hNormalization)	12
	conv2d (Conv2D)	(None, 32, 32, 64)	1792	max_pooling2d_1 (MaxPooling (None, 8, 8, 128)	
	conv2d_1 (Conv2D)	(None, 32, 32, 64)	36928	2D)	
	batch_normalization (BatchNormalization)	(None, 32, 32, 64)	256	dropout_1 (Dropout) (None, 8, 8, 128) 0 conv2d 4 (Conv2D) (None, 8, 8, 256) 29	95168
	max_pooling2d (MaxPooling2D)	(None, 16, 16, 64)	0		024
	dropout (Dropout)	(None, 16, 16, 64)	0	conv2d_5 (Conv2D) (None, 8, 8, 256) 59	90080
	conv2d_2 (Conv2D)	(None, 16, 16, 128)	73856	batch_normalization_3 (Batc (None, 8, 8, 256)	024
(1)	conv2d_3 (Conv2D)	(None, 16, 16, 128)	147584 (2	hNormalization)	
	conv2d_6 (Conv2D)	(None, 8, 8, 256)	590080	conv2d_9 (Conv2D) (None, 4, 4, 512) 2359808	
	batch_normalization_4 (BatchNormalization)	(None, 8, 8, 256)	1024	batch_normalization_7 (Batc (None, 4, 4, 512) 2048 hNormalization)	
	max_pooling2d_2 (MaxPooling 2D)	(None, 4, 4, 256)	0	max_pooling2d_3 (MaxPooling (None, 2, 2, 512) 0 2D)	
	dropout_2 (Dropout)	(None, 4, 4, 256)	0	dropout_3 (Dropout) (None, 2, 2, 512) 0	
	conv2d_7 (Conv2D)	(None, 4, 4, 512)	1180160	conv2d_10 (Conv2D) (None, 2, 2, 512) 2359808	
	batch_normalization_5 (BatchNormalization)	(None, 4, 4, 512)	2048	batch_normalization_8 (Batc (None, 2, 2, 512) 2048 hNormalization)	
	conv2d_8 (Conv2D)	(None, 4, 4, 512)	2359808	conv2d_11 (Conv2D) (None, 2, 2, 512) 2359808	
(3)	batch_normalization_6 (Batc hNormalization)	(None, 4, 4, 512)	2048 (4	batch_normalization_9 (Batc (None, 2, 2, 512) 2048 hNormalization)	


conv2d 12 (Conv2D) (None, 2, 2, 512) 2359808

```
batch_normalization_10 (Bat (None, 2, 2, 512)
          max_pooling2d_4 (MaxPooling (None, 1, 1, 512)
          dropout_4 (Dropout)
                                    (None, 1, 1, 512)
                                                            0
                                                                                                                                        524800
                                                                                 dense 2 (Dense)
                                                                                                             (None, 512)
          flatten (Flatten)
                                   (None, 512)
                                                           n
          dropout_5 (Dropout)
                                  (None, 512)
                                                           0
                                                                                 dense_3 (Dense)
                                                                                                             (None, 10)
                                                                                                                                        5130
                                  (None, 4096)
                                                          2101248
                                                          Total parans: 21,557,322
0 Trainable parans: 21,549,258
4195328 (6) Non-trainable params: 8,064
                                  (None, 4096)
                                                          0
          dropout_6 (Dropout)
 (5) dense_1 (Dense)
                                   (None, 1024)
# 定义卷积神经网络模型
model = tf.keras.Sequential([
    tf.keras.layers.Conv2D(64, 3, padding='same', activation='relu', input_shape=(32, 32, 3)), # 輸入通道數为3,輸出通道數为64,差积极大小为3,
tf.keras.layers.Conv2D(64, 3, padding='same', activation='relu',kernel_regularizer=regularizers.l2(0.001)), # 輸入通道數为64,輸出通道數为
    tf. keras. layers. BatchNormalization(),
    tf.keras.layers.MaxPooling2D(2, 2), # 最大他化层, 大小为2x2, 步幅为2
    tf.keras.layers.Dropout(0.05),
    tf.keras.layers.Conv2D(128, 3, padding='same', activation='relu'), # 輸入通道数为64,輸出通道数为128, 卷积模大小为3x3, 填充为1
tf.keras.layers.Conv2D(128, 3, padding='same', activation='relu', kernel_regularizer=regularizers.l2(0.001)), # 輸入通道数为128, 輸出通道。
    tf.keras.layers.BatchNormalization(),
# 设置 kernel_regularizer 参数来实现 L2 正则化。其中 0.001 是 L2 正则化系数。
    tf.keras.layers.MaxPooling2D(2, 2), # 最大地化层, 大小为2x2, 步幅为2
    tf.keras.layers.Dropout(0.1),
    tf.keras.layers.Conv2D(256, 3, padding same', activation='relu'), # 輸入通道数为128, 輸出通道数为256, 卷积核大小为3x3, 填充为1
    tf. keras. layers. BatchNormalization()
    tf.keras.layers.Conv2D(256, 3, padding='same', activation='relu'),
    tf.keras.layers.BatchNormalization(),
    tf.keras.layers.Conv2D(256, 3, padding='same', activation='relu', kernel_regularizer=regularizers.l2(0.001)), # 輸入通道数为256, 輸出通道。
    tf. keras. layers. BatchNormalization(),
    tf.keras.layers.MaxPooling2D(2, 2), # 最大他化层, 大小为2x2, 步幅为2
    tf.keras.layers.Dropout(0.15),
    tf.keras.layers.Conv2D(512, 3, padding='same', activation='relu'),
    tf. keras. layers. BatchNormalization (
    tf.keras.layers.Conv2D(512, 3, padding='same', activation='relu'),
    tf. keras. layers. BatchNormalization(),
    tf.keras.layers.Conv2D(512, 3, padding='same', activation='relu', kernel_regularizer=regularizers.12(0.001)), tf.keras.layers.BatchNormalization(),
    tf.keras.layers.MaxPooling2D(2, 2),
    tf. keras. layers. Dropout (0.2),
    tf.keras.layers.Conv2D(512, 3, padding='same', activation='relu'),
    tf.keras.layers.BatchNormalization(),
     \text{tf.keras.layers.Conv2D} \, (512, \ 3, \ \mathsf{padding} \texttt{='same'}, \ \mathsf{activation} \texttt{='relu'}), \\
    tf. keras. layers. BatchNormalization(),
    tf.keras.layers.Conv2D(512, 3, padding='same', activation='relu', kernel_regularizer=regularizers.l2(0.001)),
    tf.keras.layers.BatchNormalization(),
    tf.keras.layers.MaxPooling2D(2, 2),
    tf. keras. layers. Dropout (0. 25),
    tf.keras.layers.Flatten(), # 将张量展开为一维张量
    tf.keras.layers.Dropout(0.3),
    tf.keras.layers.Dense(4096, activation='relu'),
    {\tt tf.\,keras.\,layers.\,Dropout}\,(0.\,5)\,,
    tf.keras.layers.Dense(1024, activation='relu'), # 全连接层1, 输入维度为256*4*4, 输出维度为1024
tf.keras.layers.Dense(512, activation='relu',kernel_regularizer=regularizers.l2(0.001)), # 全连接层2, 输入维度为1024, 输出维度为512
    tf.keras.layers.Dense(10, activation='softmax') # 輸出层,輸入維度为512,輸出維度为10
```

实验结果:







在运行 100 个 epoch 后,模型基本收敛,最终测试集上的 accuracy 为 0.9222,训练集上的 accuracy 为 0.87560

具体到每个类别, 结果如下:

Class 0: airplane accuracy: 85.30%

Class 1: automobile accuracy: 92.90%

Class 2: bird accuracy: 86.90%

Class 3: cat accuracy: 76.30%

Class 4: deer accuracy: 85.40%

Class 5: dog accuracy: 76.30%

Class 6: frog accuracy: 91.70%

Class 7: horse accuracy: 91.80%

Class 8: ship accuracy: 95.20%

Class 9: truck accuracy: 93.70%

从防止过拟合的方面看: dropout 和 L2 正则化系数的应用在很大程度上减少了模型的过拟合程度,增加了模型的泛化能力。这使得模型在训练集上表现更好的同时在测试集上的表现也有了很大的提升。

从模型预测准确率上来看:新增加的卷积层显著提升了模型预测的准确性。

虽然模型较上一版有了很大的提升,但是具体到每个类别时,我发现 cat 和 dog 的 预测准确率偏低,与此同时,accuracy 的变化曲线还反映出了一个问题:模型收敛速度 过慢。

为了进一步提高这两种相似种类的识别正确率、加快模型收敛速度,我在对现有框架进行分析后,尝试在如下两个方面对模型进行调整:

- 1. 进一步对图像进行数据增强
- 2. 在训练过程中,随着训练轮数的增加,模型参数逐渐接近最优解,此时学习率过大会导致模型在最优点两侧来回波动,难以稳定地收敛到最优解。因此我尝试对学习率进行动态调整。

2.4 基于实验经验构建的最终网络模型(网络模型优化+学习率动态调整)

在基本框架不变的情况下,通过提高网络中正则化参数的大小和设置频率来尝试降 低模型的过拟合程度。

同时,模型采用动态学习率调整机制试图帮助优化器更好地控制学习率,从而提高 训练效果和收敛速度。

最终网络模型


最终数据增强方案

```
# 定义训练集和测试集的数据增强
train_transform = tf.keras.Sequential([
    tf.keras.layers.experimental.preprocessing.RandomFlip('horizontal'),
    tf.keras.layers.experimental.preprocessing.RandomRotation(0.1),
    tf.keras.layers.experimental.preprocessing.RandomTranslation(0.1, 0.1),
    tf.keras.layers.experimental.preprocessing.RandomZoom(0.1),
    tf.keras.layers.experimental.preprocessing.Rescaling(1./255)
])

test_transform = tf.keras.Sequential([
    tf.keras.layers.experimental.preprocessing.Rescaling(1./255)
])
```

实验结果:

```
===] - ETA: Os - loss: 0.2748 - accuracy: 0.9403
Epoch 98/100
196/196 [===
                 Epoch 00098: val_accuracy did not improve from 0.88980
196/196 [===
0.8855 - lr:
                            ===] - 48s 246ms/step - loss: 0.2679 - accuracy: 0.9425 - val_loss: 0.4995 - val_accuracy:
         6.2500e-05
Epoch 99/100
196/196 [==
                           ===] - ETA: Os - loss: 0.2719 - accuracy: 0.9411
Epoch 00099: val_accuracy did not improve from 0.88980
196/196 [====
0.8862 - lr:
                            ===] - 50s 254ms/step - loss: 0.2719 - accuracy: 0.9411 - val_loss: 0.4745 - val_accuracy:
         6.2500e-05
Epoch 100/100
196/196 [====
                Epoch 00100: val_accuracy did not improve from 0.88980
196/196 [==
                            ===] - 50s 254ms/step - loss: 0.2669 - accuracy: 0.9425 - val_loss: 0.4646 - val_accuracy:
0.8897 - 1r: 6.2500e-05
```



在运行 100 个 epoch 后,模型收敛,最终测试集上的 accuracy 为 0.9425,训练集上的 accuracy 为 0.8898

具体到每个类别, 结果如下:

Class 0: airplane accuracy: 90.70% Class 1: automobile accuracy: 96.30%

Class 2: bird accuracy: 86.30%

Class 3: cat accuracy: 78.30%
Class 4: deer accuracy: 87.10%
Class 5: dog accuracy: 79.40%
Class 6: frog accuracy: 95.60%
Class 7: horse accuracy: 90.80%
Class 8: ship accuracy: 92.30%
Class 9: truck accuracy: 93.00%

从防止过拟合的方面看:修改和新添加的正则化参数减少了模型的过拟合程度,增加了模型的泛化能力。这使得模型在训练集上表现更好的同时在测试集上的表现也有了很大的提升。

从模型预测准确率上来看:新增加的数据增强方法以及学习率动态调整机制在一定程度上进一步提升了模型预测的准确性。

从模型收敛速度看:相较于之前的版本,学习率动态调整机制显著加快了模型的收敛速度,从绘制的图表中也可以清晰的看到,模型最终收敛的很好。

综上,最终的模型在预测准确率、单项预测准确率、收敛速度、泛化能力上都有了明显的提升。


3. 实验分析

3.1 实验结果分析


任务要求:设计一个卷积神经网络, 在 CIFAR-10 数据集上实现分类任务。

实验结果: 在本实验的架构基础上,经过 100 个 epoch 的训练,最终模型取得的训练结果如下:


Loss: 测试集: 0.45 左右




Accuracy: 测试集: 0.9 左右



Class of Accuracy:



Confusion Matrix:



根据如上评价指标,可以发现本次设计的网络模型较好的实现了要求的十分类任务。

3.2 不同网络结构对比(含激活函数对比)

1) 网络层数增加

根据上述 2.2 与 2.3 的结果,一定范围内增加网络的层数可以显著提升模型的预测能力。

2) 数据增强

根据上述 2.1 与 2.2 的结果,数据增强操作可以在一定程度上提升模型的预测能力。

3) 正则化参数

根据上述 2.1 和 2.2 的结果,从防止过拟合的方面看。dropout 和 L2 正则化系数的应用在很大程度上减少了模型的过拟合程度,增加了模型的泛化能力。

4) 学习率调整

学习率动态调整机制显著加快了模型的收敛速度,使得模型可以稳定地收敛到最优 解

5) 设置不同的激活函数

在实验中尝试将 relu 函数更换为 sigmoid 函数,使用 wandb 在训练过程中进行实时观测。在运行的过程中,可以观察到 sigmoid 激活函数在该问题中表现不佳,relu 函数在设置的模型中的表现明显优于 sigmoid 函数。

4. 总结

4.1 实验总结

本次实验设计了一个相对较深的网络模型,较好的实现了要求的基于卷积神经网络的 CIFAR-10 数据集分类任务。在实验的过程中我也对网络的整体架构以及网络的优化方案有了更加清晰的认识。

4.2 提交文件

包含实验报告、最终源代码(cv2_new_model_lr.ipynb)、部分过程源代码、实验结果文件、保存的模型(.PNG、.ipynb、.h5)

```
cv2_new_model_1r.ipynb
刘方兴-U202015550-实验报告 2.doc
<del>1</del>_20_防止过拟合
model accuracy.png
model loss.png
my_model1.h5
   40_防止过拟合
accuracy of class.png
       accuracy. png
       confusion matrix.png
cv_ex2.ipynb
loss.png
model.png
my_model2.h5
       process. png
      -ipynb_checkpoints
<del>d</del>emo
         demo_structure.png
model accuracy.png
model loss.png
         my_model_demo.h5
         process. png
超参数设置. png
<del>f</del>inal
         accuracy of class.png
         accuracy. png
         confusion matrix.png
cv2_new_model_lr.ipynb
         final_best.h5
final_final.h5
         loss. png
<del>n</del>ew_model
         accuracy of class.png
         accuracy. png
         confusion matrix.png
cv2_new_model.ipynb
        loss.png
model_structure.png
new_model.png
new_model_best.h5
new_model_final.h5
训练过程.png
```